ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΈΑΣ ΣΥΣΤΗΜΆΤΩΝ ΜΕΤΆΔΟΣΗΣ ΠΛΗΡΟΦΟΡΊΑΣ ΚΑΙ ΤΕΧΝΟΛΟΓΊΑΣ ΥΛΙΚΩΝ

ΣΚΙΑΓΡΑΦΗΜΑ

της εξαμηνιαίας εργασίας με τίτλο:

«ΑΝΑΛΥΣΗ ΤΟΥ ΕΝΤΕΡΙΚΟΥ ΜΙΚΡΟΒΙΟΤΟΠΟΥ ΜΕ ΧΡΗΣΗ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΓΙΑ ΜΕΛΕΤΗ ΔΙΑΦΟΡΩΝ ΦΥΛΟΥ»

για το μάθημα:

Τεχνολογίες Κινητής & Ηλεκτρονικής Υγείας

Διδάσκοντες: Κ. Νικήτα, Γ. Ματσόπουλος, Π. Τσανάκας, Ι. Δελής

ΜΕΛΗ ΤΗΣ ΟΜΑΔΑΣ & ΡΟΛΟΙ

Υπεύθυνος Επικοινωνίας:

Ψυχής Μιχαήλ (ΑΜ: 03122094)

Υπεύθυνος Συντονισμού Γραπτής Αναφοράς:

Παπακώστας Αχιλλέας (ΑΜ: 03122201)

Υπεύθυνος Συντονισμού Παρουσίασης:

Τσάκαλος Θεόδωρος (ΑΜ: 03121668)

Υπεύθυνος Συντονισμού Σκιαγραφήματος & Τεχνήματος:

Τσουρούφλη Ζωή (ΑΜ: 03122062)

ΠΕΡΙΛΗΨΗ

Η σύσταση του εντερικού μικροβιότοπου επηρεάζει καθοριστικά τη διατήρηση της ομοιόστασης και, κατ' επέκταση, την ανθρώπινη υγεία. Η δυσβίωση (microbiota dysbiosis), δηλαδή η διαταραχή της ισορροπίας του εντερικού μικροβιότοπου, έχει συσχετιστεί με χρόνιες φλεγμονώδεις αντιδράσεις και με την εμφάνιση πολλών ασθενειών. Η σύσταση του εντερικού μικροβιώματος επηρεάζεται από πολλούς παράγοντες, όπως η διατροφή, ο τρόπος ζωής, η ηλικία και το φύλο. Ωστόσο, ο παράγοντας του βιολογικού φύλου συχνά δεν λαμβάνεται επαρκώς υπόψη στον σχεδιασμό διαγνωστικών μοντέλων.

Στην παρούσα εργασία αξιοποιούνται δεδομένα από τον εντερικό μικροβιότοπο για την ανάπτυξη μοντέλων μηχανικής μάθησης, ικανών να αναγνωρίζουν μικροβιακά μοτίβα (microbial patterns) και βιοδείκτες (biomarkers) που διαφοροποιούνται ανάλογα με το φύλο και σχετίζονται με την προδιάθεση και την εμφάνιση καρκίνου του παχέος εντέρου.

Ιδιαίτερη έμφαση δίνεται στην έννοια της αλγοριθμικής δικαιοσύνης (fairness in AI), καθώς τα συμβατικά μοντέλα συχνά εμφανίζουν μεροληψία εις βάρος συγκεκριμένων δημογραφικών ομάδων λόγω ανισορροπιών στα δεδομένα εκπαίδευσης. Για την αντιμετώπιση του φαινομένου αυτού, εφαρμόζονται εξειδικευμένες τεχνικές άμβλυνσης της μεροληψίας. Μέσω της προσέγγισης αυτής, επιδιώκεται η ανάπτυξη δίκαιων και αξιόπιστων μοντέλων, τα οποία θα διασφαλίζουν υψηλή διαγνωστική ακρίβεια και για τα δύο βιολογικά φύλα.

Λέξεις Κλειδιά:

Εντερικός Μικροβιότοπος, Μηχανική Μάθηση, Διαφορές Φύλου, Καρκίνος Παχέος Εντέρου, Αλγοριθμική Δικαιοσύνη

ΠΡΟΒΛΗΜΑΤΑ & ΣΤΟΧΟΙ

Πρόβλημα

Το πρόβλημα που στοχεύουμε να αντιμετωπίσουμε είναι η ανεπαρκής συμπερίληψη του φύλου ως παράγοντα που επηρεάζει την λειτουργία του εντερικού μικροβιότοπου και την εμφάνιση της νόσου του καρκίνου του παχέος εντέρου. Η μη-συμπερίληψη του φύλου στην ανάπτυξη διαγνωστικών μοντέλων καθιστά τα συγκεκριμένα μοντέλα αναποτελεσματικά διότι είτε αγνοούν πλήρως τον παράγοντα του φύλου [3] είτε έχουν εκπαιδευτεί σε σύνολα δεδομένων που περιλαμβάνουν συμμετέχοντες μόνο ενός φύλου και εσφαλμένα χρησιμοποιούνται προς εξαγωγή διαγνώσεων σε συμμετέχοντες διαφορετικού φύλου [4].

Επικαιρότητα προβλήματος

Το πρόβλημα είναι ιδιαίτερα επίκαιρο, καθώς η χρήση μηχανικής μάθησης διευκολύνει την ανάλυση πολύπλοκών βιολογικών δεδομένων, συμπεριλαμβανομένων και δεδομένων σχετικών με τον εντερικό μικροβιότοπο [5]. Ταυτόχρονα, η σύγχρονη έρευνα δείχνει ότι υπάρχουν σημαντικές διαφορές στον εντερικό μικροβιότοπο μεταξύ των φύλων, οι οποίες επηρεάζονται από ορμονικούς, γενετικούς και περιβαλλοντικούς παράγοντες [6]. Η κατανόηση αυτών των διαφορών μπορεί να συμβάλει στην ανάπτυξη πιο εξατομικευμένων και δίκαιων διαγνωστικών μοντέλων.

Στόχοι

Οι στόχοι της εργασίας είναι: (α) η ανάλυση δεδομένων εντερικού μικροβιότοπου με στόχο τον εντοπισμό διαφορών μεταξύ ανδρών και γυναικών, (β) η αξιολόγηση της απόδοσης των μοντέλων ξεχωριστά για κάθε φύλο και (γ) η διερεύνηση βιοδεικτών του μικροβιότοπου που σχετίζονται με το φύλο και την ασθένεια.

Καινοτομία προσέγγισης

Η καινοτομία της προσέγγισής μας έγκειται στην εστίαση ρητά στις διαφορές φύλου και στη δίκαιη αξιολόγηση των μοντέλων μηχανικής μάθησης. Συγκεκριμένα, θα συγκρίνουμε την απόδοση των μοντέλων μεταξύ ανδρών και γυναικών και θα εφαρμόσουμε τεχνικές που μειώνουν πιθανές μεροληψίες, συμβάλλοντας έτσι στην ανάπτυξη πιο αξιόπιστων και εξατομικευμένων διαγνωστικών μοντέλων.

ΜΕΘΟΔΟΛΟΓΙΑ ΑΝΑΛΥΣΗΣ, ΤΕΧΝΟΛΟΓΙΕΣ & ΕΡΓΑΛΕΙΑ ΠΡΟΣ ΧΡΗΣΗ

Για την υλοποίηση της εργασίας, η μεθοδολογία θα περιλαμβάνει αρχικά στατιστική ανάλυση των δεδομένων του εντερικού μικροβιότοπου, με στόχο τη διερεύνηση της κατανομής των taxa και τον εντοπισμό διαφορών μεταξύ των φύλων. Στη συνέχεια, θα εφαρμοστούν τεχνικές Μη Επιβλεπόμενης Μάθησης (Unsupervised Learning), προκειμένου να αναγνωριστούν φυσικές ομαδοποιήσεις και πρότυπα στα δεδομένα χωρίς τη χρήση ετικετών. Η επιλογή αυτή έγινε λόγω των δύο βασικών ιδιαιτεροτήτων των δεδομένων του μικροβιότοπου:

- την υψηλή διαστατικότητα (παρουσία χιλιάδων διαφορετικών ειδών βακτηρίων)
- και τη μεγάλη αραιότητα (sparsity), καθώς πολλά είδη απουσιάζουν από μεγάλο τμήμα του πληθυσμού.

Οι μέθοδοι που θα χρησιμοποιηθούν συγκεκριμένα είναι οι εξής:

- Θα εφαρμοστούν αλγόριθμοι clustering, όπως ο K-Means και ο DBSCAN. Στόχος είναι να ανακαλύψουμε τις φυσικές ομαδοποιήσεις και ομοιότητες των ασθενών βάσει των μικροβιακών τους δεδομένων.
- Αφού ο αλγόριθμος δημιουργήσει τις ομάδες, θα ακολουθήσει στατιστικός έλεγχος για να διαπιστωθεί η σύνθεσή της κάθε ομάδας.
- Αξίζει να αναφερθεί πως πριν τη συσταδοποίηση, θα χρησιμοποιηθούν τεχνικές, όπως η PCA ή ο αλγόριθμος t-SNE, για τη μείωση των διαστάσεων και την καλύτερη οπτικοποίηση των δεδομένων.

Η προσέγγισή μας για τη διερεύνηση των διαφορών φύλου θα κινηθεί σε δύο άξονες:

- *Διαχωρισμός Δεδομένων:* Ανάπτυξη και εκπαίδευση ξεχωριστών μοντέλων αποκλειστικά για άνδρες και αποκλειστικά για γυναίκες, με στόχο τη σύγκριση των συστάδων (clusters) που προκύπτουν.
- *Ενσωμάτωση Χαρακτηριστικού:* Εκπαίδευση ενός ενιαίου μοντέλου όπου το «φύλο» θα αποτελεί επιπλέον χαρακτηριστικό (feature), προκειμένου να μελετηθεί η βαρύτητά του στη διαμόρφωση των ομάδων.

Για την επιβεβαίωση της γενίκευσης η μεθοδολογία θα αναπτυχθεί και θα βελτιστοποιηθεί σε ένα αρχικό σύνολο δεδομένων και στη συνέχεια θα αξιολογηθεί (cross-study validation) σε ανεξάρτητα ανοιχτά σύνολα. Ως εργαλεία υλοποίησης θα χρησιμοποιηθούν η γλώσσα Python και οι βιβλιοθήκες Scikit-Learn (μοντελοποίηση), Pandas/NumPy (προεπεξεργασία) και Seaborn (οπτικοποίηση).

Τέλος, θα εφαρμοστούν τεχνικές Επιβλεπόμενης Μάθησης (Supervised Learning), όπως Random Forest και Support Vector Machine (SVM), για την ανάπτυξη μοντέλων πρόβλεψης της πιθανότητας εμφάνισης καρκίνου του παχέος εντέρου βάσει χαρακτηριστικών της σύστασης του εντερικού μικροβιότοπου αλλά και διαφορών που σχετίζονται με τον παράγοντα του φύλου.

ΠΡΟΒΛΗΜΑΤΑ: ΠΡΟΒΛΕΨΗ ΑΝΤΙΜΕΤΩΠΙΣΗΣ

Κατά την εκπόνηση της εργασίας, αναμένεται να αντιμετωπιστούν οι εξής προκλήσεις:

1. *Περιορισμένη Διαθεσιμότητα & Ανομοιογένεια Ανοιχτών Δεδομένων:* Διαφορετικές μελέτες χρησιμοποιούν διαφορετικά πρωτόκολλα. Αντιμετώπιση με εφαρμογή αυστηρών τεχνικών κανονικοποίησης και μετασχηματισμών (π.χ. Centered Log-Ratio) πριν τον έλεγχο μεταφερσιμότητας.

2. *Υψηλή Αραιότητα (Sparsity) Μικροβιώματος:* Η απουσία πολλών βακτηρίων δυσκολεύει τους αλγορίθμους αποστάσεων, όπως τον K-Means. Αντιμετώπιση με χρήση μετρικών κατάλληλων για τέτοια δεδομένα ή κατάλληλη μείωση διαστάσεων.

3. *Αξιολόγηση Unsupervised Μοντέλων:* Η απουσία labels καθιστά δύσκολη την αξιολόγηση. Αντιμετώπιση με χρήση εσωτερικών μετρικών αξιολόγησης συστάδων.

4. *Μη Ισορροπημένα Δεδομένα (Gender Imbalance):* Η άνιση κατανομή ανδρών και γυναικών στα datasets μπορεί να οδηγήσει σε μη δίκαια μοντέλα (έλλειψη fairness). Αντιμετώπιση με εφαρμογή τεχνικών υποδειγματοληψίας (undersampling) στο στάδιο της προεπεξεργασίας.

5. *Υπερεκπαίδευση (Overfitting) λόγω Υψηλής Διαστατικότητας:* Τα δεδομένα μικροβιότοπου περιέχουν συνήθως χιλιάδες χαρακτηριστικά (είδη βακτηρίων) αλλά συγκριτικά μικρό αριθμό δειγμάτων (ασθενών) με αποτέλεσμα την υπερπροσαρμογή των δεδομένων εκπαίδευσης από τα επιβλεπόμενα μοντέλα και κατ' επέκταση την αποτυχία γενίκευσής τους σε νέα, άγνωστα δείγματα. Αντιμετώπιση με αυστηρή επιλογή χαρακτηριστικών (feature selection) με σκοπό τη διατήρηση μόνο στατιστικά σημαντικών βακτηρίων.

ΧΡΟΝΟΔΙΑΓΡΑΜΜΑ

Το χρονοδιάγραμμα της εργασίας εκτείνεται ενδεικτικά σε 11 εβδομάδες, χωρισμένο σε έξι αλληλεπικαλυπτόμενες φάσεις. Οι εβδομάδες 1-4 αφορούν τη βιβλιογραφική μελέτη και προετοιμασία δεδομένων. Στη συνέχεια (εβδομάδες 4-8), αναπτύσσονται τα μοντέλα μηχανικής μάθησης και αξιολογούνται οι διαφορές φύλου. Τέλος, οι εβδομάδες 8-11 εστιάζουν στην εφαρμογή τεχνικών δικαιοσύνης (fairness) και τη συγγραφή της τεχνικής αναφοράς.

Εβδομάδα	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**	**11**
Βιβλιογραφική Ανασκόπηση											
Προετοιμασία Δεδομένων											
Ανάπτυξη Μοντέλων ML											
Αξιολόγηση & Διαφορές Φύλου											
Εφαρμογή Τεχνικών Fairness											
Συγγραφή & Παρουσίαση											

Διάγραμμα Gantt

ΔΟΜΗ

Η τελική αναφορά θα περιλαμβάνει ενδεικτικά τις ακόλουθες επιμέρους ενότητες:

ΕΝΟΤΗΤΑ	ΤΙΤΛΟΣ	ΠΕΡΙΓΡΑΦΗ	ΥΠΕΥΘΥΝΟΣ ΕΚΠΟΝΗΣΗΣ
1	Εισαγωγή	Περιγραφή του προβλήματος, της σημασίας του εντερικού μικροβιώματος στον καρκίνο του παχέος εντέρου και ανάλυση των στόχων της εργασίας	Τσάκαλος Θεόδωρος
2	Βιβλιογραφική Ανασκόπηση	Παρουσίαση της υπάρχουσας βιβλιογραφίας σχετικά με τις διαφορές φύλου στο μικροβίωμα και τη χρήση αλγορίθμων μηχανικής μάθησης στη βιοπληροφορική	Παπακώστας Αχιλλέας
3	Προεπεξεργασία Δεδομένων & Μεθοδολογία	Παρουσίαση των ανοικτών συνόλων δεδομένων, ανάλυση των τεχνικών αραιότητας (sparsity) και των μεθόδων μείωσης διαστάσεων (PCA/t-SNE)	Ψυχής Μιχαήλ
4	Ανάπτυξη Μοντέλων & Ανάλυση Συστάδων (Clustering)	Υλοποίηση των αλγορίθμων Μη Επιβλεπόμενης Μάθησης (K-Means, DBSCAN), εφαρμογή των μεθοδολογικών στρατηγικών (εκπαίδευση ξεχωριστών μοντέλων ανά φύλο έναντι ενσωμάτωσης του φύλου ως feature στο ενιαίο μοντέλο) και εξαγωγή των συστάδων	Τσουρούφλη Ζωή
5	Αξιολόγηση, Επαλήθευση & Συμπεράσματα	Αξιολόγηση των συστάδων (με χρήση μετρικών), cross-study validation σε νέα datasets, εφαρμογή αλγορίθμων Επιβλεπόμενης Μάθησης (Random Forest, SVM), βιολογική ερμηνεία των ευρημάτων ανά φύλο και τελικά συμπεράσματα	Τσάκαλος Θεόδωρος Παπακώστας Αχιλλέας Ψυχής Μιχαήλ Τσουρούφλη Ζωή

ΒΙΒΛΙΟΓΡΑΦΙΑ

Παρατίθεται ενδεικτική βιβλιογραφία που αναμένεται να μελετηθεί και να χρησιμοποιηθεί στο πλαίσιο εκπόνησης της εργασίας. Συγκεκριμένα, πρόκειται να πραγματοποιηθεί μελέτη πηγών αναφορικά με:

- το βιολογικό υπόβαθρο του εντερικού μικροβιότοπου [1], [6]
- τη χρήση μηχανικής μάθησης στην προσπάθεια συσχέτισης του εντερικού μικροβιότοπου με τον καρκίνο του παχέος εντέρου [2], [7], [8], [9], [10]
- τη μεροληψία φύλου και τη δικαιοσύνη της χρήσης τεχνητής νοημοσύνης στον τομέα της υγείας και της βιοϊατρικής [3], [4], [5].

[1] Org, E., et al. (2016). “Sex differences and hormonal effects on gut microbiota composition in mice and humans.” Gut Microbes, 7(4), 313–322.

[2] Tsai, Y.-J., Lyu, W.-N., Liao, N.-S., et al. (2025). Gut microbiome-based machine learning model for early colorectal cancer and adenoma screening. Gut Pathogens, 17, 50.

[3] Larrazabal, A. J., Nieto, N., Peterson, V., Milone, D. H., & Ferrante, E. (2020). Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis. Proceedings of the National Academy of Sciences (PNAS)

[4] Mendez, M., Jafarpisheh, N., Demello, S., Lee, C., Dang, M., & Tyrrell, P. N. (2025). Evaluating the impact of sex bias on AI models in musculoskeletal ultrasound of joint recess distension. PLOS ONE, 20(1), e0305292

[5] Bajwa, J., et al. (2021). Artificial intelligence in healthcare: Transforming the practice of medicine. Future Healthcare Journal.

[6] Yoon, K., et al. (2021). Roles of sex hormones and gender in the gut microbiota. Journal of Neurogastroenterology and Motility

[7] Wirbel, J., Pyl, P. T., Kartal, E., et al. (2019). Meta-analysis of fecal metagenomes reveals global microbial signatures of colorectal cancer. *Nature Medicine*, 25(4), 679–689.

[8] Thomas, A. M., Manghi, P., Asnicar, F., et al. (2019). Metagenomic analysis of colorectal cancer datasets identifies cross-cohort microbial biomarkers. *Nature Medicine*, 25(4), 667–678.

[9] Pasolli, E., Truong, D. T., Malik, F., Waldron, L., & Segata, N. (2016). Machine learning meta-analysis of large metagenomic datasets: tools and biological insights. *Nature Communications*, 7, 12579.

[10] Topçuoğlu, B. D., Lesniak, N. A., Ruffin, M. T., Wiens, J., & Schloss, P. D. (2020). A framework for effective application of machine learning to microbiome-based classification problems. *mBio*, 11(3), e00434-20.